

RAPPORT DE PROJET - L1 - E

PROJET Python
“My First Chatbot”

Projet réalisé par

Arthur BOUTELIER
Victor PROFFIT

Projet encadré par

Kaïs KLAI
Nicolas FLASQUE

I Introduction

Dans le cadre de notre projet de fin de semestre de programmation en Python nous avons été confronté au défi de taille qui est de coder un Chatbot en langage python et c'est ce que nous allons vous présenter. Notre programme nommé Chatbot va vous permettre via des documents donnés de répondre à des questions posées par l'utilisateur ainsi que diverses informations sur les textes.

Présentation de nos fonctionnalités :

Lorsque vous exécutez notre programme vous allez devoir choisir un thème entre trois imposé:

- La politique contenant le corpus de texte fourni
- L'éducation
- L'égalité Homme Femme

Vous allez alors devoir choisir entre 2 mode :

- Le mode d'information sur les textes qui permet d'obtenir des informations sur le corpus de documents.
On peut obtenir :
 - Les mots les moins important
 - Les mots avec le plus grand score tf-idf
 - Le/les mot(s) les plus utilisé par un auteur
 - Le/les auteur(s) qui a/ont le plus dit un mot
 - Tous les auteurs qui ont dit un mot
 - Le premier auteur ayant parlé de certains termes
 - Tous les mots à la fois important et cité par tous les auteurs
- Le mode Chatbot qui à partir d'une question va chercher le meilleurs moyens d'y répondre à l'aide des phrases données par les documents.

Notre ChatBot s'organise comme cela :

- Un dossier principale contenant 3 dossiers et 3 fichiers

 Cleaned	19/12/2023 07:53	Dossier de fichiers	
 Ressource	18/12/2023 16:13	Dossier de fichiers	
 Speeches	19/12/2023 07:53	Dossier de fichiers	
 function	19/12/2023 07:53	Fichier source Pyth...	40 Ko
 main	19/12/2023 07:57	Fichier source Pyth...	5 Ko
 README	19/12/2023 07:53	Fichier source Mar...	2 Ko

- Les dossiers Cleaned et Speeches qui possèdent chacun des sous dossiers correspondant aux thèmes et contenant les textes:

 Education	19/12/2023 07:53	Dossier de fichiers	
 Egalite_homme_femme	19/12/2023 07:53	Dossier de fichiers	
 Politique	19/12/2023 07:53	Dossier de fichiers	

- Le dossier Ressource qui va contenir les fichiers autres que les textes nécessaires pour faire fonctionner le programme:

 Lexique	18/12/2023 16:13	Document texte	0 Ko
 nom_president	23/11/2023 16:15	Document texte	1 Ko

- Et enfin les fichiers function qui va contenir toutes les fonctions du programme, main qui va être le fichier à exécuter pour lancer le ChatBot et enfin le fichier ReadMe donnant des informations sur le projet

II Présentation technique

- Chatbot :
 - Fonctionnement :

Le Chatbot va récupérer une question donnée par l'utilisateur et va la traiter afin d'obtenir un tableau de mot en minuscule, sans ponctuation et où chaque case représente un mot. Ensuite on va chercher à trouver le document ayant le plus de similarité avec la question via la similarité des cosinus. On va alors prendre le mot le plus important de la question et afficher à l'utilisateur la première phrase dans laquelle il apparaît tout en effectuant de petit traitement afin d'améliorer la réponse.
 - Structures de données :

Tf-idf de la question et de la matrice: List car cela permet d'avoir une dimension vectorielle

Les différents TF et IDF: dictionnaire :

Cette structure de données permet de facilement accéder aux valeurs depuis les mots et inversement ce qui est très utile en vue de leur utilisation.
 - Problème rencontré :

Quelque difficulté à lier une ligne de notre matrice à un mot on est donc passé par des listes de correspondances ou on place le mot aux même indice que sa valeur

- Les mots les moins important :
 - Fonctionnement :

Un mot est dit non important si jamais son score tf-idf est nul dans tous les documents. Or cela n'est possible uniquement dans le cas où son score idf est égale à 0 car son score TF ne peut pas être nul dans tous les docs. On récupère donc tous les mots ayant un score IDF nul et on les places dans un tableaux
 - Structures de données:

L'IDF: dictionnaire: permet de facilement lier les valeurs avec les mots.
 - Problème rencontré:

Le principal problème auquel nous avons fait face est un problème d'optimisation car nous voulions éviter de entièrement parcourir la matrice TF-IDF. On a donc préféré parcourir IDF qui est plus petite.

- Les mots avec le plus grand score tf-idf :
 - Fonctionnement :

On calcule au préalable la matrice TF IDF du corpus et on va parcourir cette matrice afin d'obtenir la valeur maximum que l'on va ensuite associer à un mot à l'aide d'une liste de correspondance.
 - Structures de données :

Le TF IDF: Matrice: Cette structure de données permet à la fois d'avoir une dimension vectorielle ainsi que la possibilité .

Liste de correspondance : liste: De dimension M nombre de lignes de la matrice précédente. Comme on voulait avoir une correspondance avec la matrice l'ordre des éléments était important ce qui nous a pousser à utiliser cette structure
 - Problème rencontré :

Créer un lien entre un mot et son score TF-IDF était un peu compliqué nous avons donc utilisé une liste de correspondance
- Le/les mot(s) les plus utilisé par un auteur :
 - Fonctionnement :

On commence par fusionner tous les textes dit par un même auteur et on applique ensuite la fonction TF qui va nous renvoyer le nombre d'occurrence de chacun des mots. On récupère alors le ou les mots avec le score TF le plus élevé avant de les afficher.
 - Structures de données :

TF: dictionnaire: permet de facilement lier les valeurs avec les mots.
 - Problème rencontré :

Fusionner les textes car certains auteurs avaient écrit plusieurs textes cela nous a poussé à modifier notre fonction calculant le score TF.
- Le/les auteur(s) qui a/ont le plus dit un mot :
 - Fonctionnement :

On va commencer par fusionner les textes écrits par un même auteur avant de récupérer le nombre d'occurrences du mot dans ce texte et on récupère le président associé à la valeur la plus élevé et on l'affiche
 - Problème rencontré :

Fusionner les textes car certains auteurs avaient écrit plusieurs textes cela nous a poussé à modifier notre fonction calculant le score TF.

- Tous les auteurs qui ont dit un mot :
 - Fonctionnement :

On va créer un tableau, parcourir les fichiers et vérifier si le mot est présent dans ce dernier et si c'est le cas et que le président et pas dans la liste on l'ajoute. Une fois tous les fichiers passé on renvoie le tableau
 - Problème rencontré :

Lié le nom d'un fichier avec un auteur. On a donc décidé de universalisé la manière de nommer les fichiers comme suit:
Nomination_Nom_auteur_numéros_du_texte.txt

- Le premier auteur ayant parlé de certains termes :
 - Fonctionnement :

Pour chaque fichier on va récupérer l'indice de la première occurrence de ce mot et on va la comparer avec celle des autres documents afin d'obtenir le document associé à l'occurrence la plus petite. On effectue alors un traitement sur le nom du document pour en faire ressortir le nom de l'auteur
 - Problème rencontré :

Lié le nom d'un fichier avec un auteur. On a donc décidé de universalisé la manière de nommer les fichiers comme suit:
Nomination_Nom_auteur_numéros_du_texte.txt

- Tous les mots à la fois important et cité par tous les auteurs :
 - Pour cela on va fusionner les textes d'un même auteur et on va ensuite récupérer le dictionnaire TF de chacun de ces textes pour les ajouter dans une liste. Cette liste serait donc une liste de dictionnaires. On récupère ensuite le plus petit dictionnaire. On va alors parcourir les clés de ce dictionnaire qui sont les mots et on va regarder le nombre d'auteurs l'ayant mentionné. Si ce nombre est égale aux nombres d'auteur on l'ajoute dans une liste que l'on renvoie à la fin du processus.
 - Structures de données :

TF: dictionnaire: permet de facilement lier les valeurs avec les mots.
 - Problème rencontré :

Encore une fois, nous avons cherché à optimiser le programme. On a donc utilisé le dico contenant le moins de mots afin de réduire drastiquement le temps d'exécution

III Présentation des résultats :

Lorsque nous lançons le programme nous devons choisir un thème comme dans la capture d'écran suivante :

```
Veuillez choisir une thématique entre celle possible :  
-1: Discours de président  
-2: Education  
-3: L'égalité Homme Femme
```

Dans notre cas, nous allons étudié les discours des présidents.

Résultat affiché :

- Afficher les mots les moins importants :

```
'messieurs', 'les', 'mesdames', 'en', 'ce', 'je', 'la', 'de', 'me', 'une', 'le', 'a', 'france', 'qui', 'se', 'et', 'dans', 'peuple', 'aux', 'que', 'son', 'histoire'
```

```
'histoire', 'pour', 'par', 'des', 'il', 'est', 'mais', 'faire', 'du']
```

- Mot avec le plus grand score TF-IDF :

```
['doit']
```

- Afficher les mots les plus dit par un auteur pour Chirac :

```
Chirac  
à
```

- Afficher les auteurs ayant le plus dit un mot avec le mot Nation :

```
nation  
['Chirac']
```

- Afficher tous les auteurs ayant dit un mot avec le mot patrie :

```
patrie  
['Mitterrand']
```

- Afficher le premier auteurs ayant parlé de certains climats ou d'écologie :

```
Veuillez entrer un terme  
climat  
Veuillez entrer un terme  
ecologie  
Macron
```

- Afficher les mots à la fois important et cité par tous :

```
['politique', 'ne', 'pas', 'ont', 'confiance', 'mai', 'sont', 'chacun', 'leur', 'cette', 'droits', 'avec', 'lui', 'avenir', 'un']
```

Maintenant présentons quelques réponses du ChatBot :

Saisissez votre question : *Peux-tu me dire si une nation peut-elle prendre soin du climat ?*

Oui, bien sûr! Et je songe bien sûr à François Hollande, faisant oeuvre de précurseur avec l'Accord de Paris sur le climat et protégeant les Français dans un monde frappé

Ou encore :

Saisissez votre question : *Quel est la nation la plus forte dans le monde?*

Quel que soit notre âge, quelles que soient nos convictions, où que nous vivions --dans l'Hexagone ou dans les Outre mers-- dans nos villes comme dans nos quartiers
et nos territoires ruraux, nous sommes la France.

IV Conclusion :

Ce projet nous a beaucoup appris notamment sur le plan technique ou la manipulation des différentes structures de données a été amené à un très haut niveau. De plus nous avons également appris à nous servir de ce fabuleux outil qu'est Github même si la prise en main était un peu difficile au début nous avons compris la puissance de l'outil.

De plus le projet étant très dense cela nous a poussé à nous diviser la tâche permettant ainsi de développer nos compétence d'organisations et de communication car il fallait que notre code soit lisible en adéquation avec le reste du code afin que notre coéquipier puisse les comprendre.

Enfin la densité du projet nous a poussé à optimiser notre temps en ne codant pas 2 fois les mêmes fonctions où en faisant en sorte que les fonctions soient utilisables dans différents cas. C'est par exemple le cas de notre fonction TF qui soit renvoie une chaîne de caractère soit écrit cette chaîne dans un fichier selon la manière dont elle est appelée. Nous avons également appris l'importance de tester ses fonctions correctement après les avoir écrites car cela nous a permis d'éviter d'avoir à revenir dessus plus tard et d'avoir des difficultés à savoir où est l'erreur.